

Contexto de Negócios e Perguntas

A temática da violência urbana é uma questão recorrente no cotidiano do município do Rio de Janeiro, englobando um amplo conjunto de fenômenos subdivididos em categorias, como roubos, furtos, agressões, homicídios, etc. Atos violentos ocorrem de formas recorrentes em toda a extensão do território, porém carregam motivos, consequências e recorrências distintas.

Para a construção de estratégias de enfrentamento à violência urbana, é necessário que estes atos violentos sejam, para além de categorizados, registrados e dimensionados para a construção de estratégias mais eficientes e para uma compreensão mais aprofundada sobre o assunto, de formas panorâmicas e específicas.

Estes dados e análises são produzidos dentro e fora do Estado, se tornando instrumentos cruciais para enfrentamento mais eficiente da problemática. Dentro da esfera pública, pode-se citar contribuições muito pertinentes do Instituto de Pesquisa Econômica Aplicada (IPEA), com seu lançamento anual do Atlas da Violência¹ e do Instituto de Segurança Pública (ISP), com a série histórica de monitoramento de letalidade e grupos vulneráveis².

Para além dos acúmulos de dados produzidos e levantados em instituições estatais, existem instituições não-governamentais que produzem, mapeiam, sistematizam e publicam dados e relatórios que preenchem lacunas - e muitas vezes disputam narrativas - em relação aos dados governamentais.

Dentro destes grupos, o Instituto Fogo Cruzado surge com o intuito de construir uma base de dados aberta e detalhada dos tiroteios que ocorrem em todo o estado³, possibilitando a produção de análises trianguladas (com outros dados pertinentes) e mais qualificadas sobre esse tipo de violência.

¹ <https://www.ipea.gov.br/portal/agenda-de-eventos/16382-lancamento-do-atlas-da-violencia-2027>

² <https://www.ispvisualizacao.rj.gov.br/grupos.html>

³ Não se limitando ao estado do Rio de Janeiro, o instituto também produz dados referentes aos estados da Bahia, Pará e Pernambuco.

Os dados produzidos pelo Instituto Fogo Cruzado envolvem, além do ato do tiroteio, informações específicas sobre o local das ocorrências, a presença ou ausência de agentes policiais, números de feridos e baixas, além de coordenadas georreferenciadas.

Compreendendo o cenário apresentado, esse MVP propõe a construção de um pipeline para sistematização do dataset do Instituto Fogo Cruzado, somado a dados de suporte do DATA.Rio, portal oficial da prefeitura da cidade. O objetivo deste processo é a criação de um sistema de banco de dados relacional em esquema estrela, que servirá como instrumento principal para as análises a serem realizadas.

Desse modo, o objetivo geral/principal é descobrir se existe uma relação direta entre as dimensões espaciais, temporais e letais dos tiroteios que ocorreram na cidade do Rio de Janeiro entre 2020 e 2025. Os objetivos específicos orbitam na produção de dados qualificados das dimensões supracitadas, com tabelas que apresentem as diferentes incidências distribuídas de formas multiescalares. Para a dimensão espacial, análises por Área de Planejamento (AP), Região de Planejamento (RP) e bairro. Para a dimensão temporal, análises anuais, semestrais e trimestrais. Para a dimensão letal, número de baixas de civis e agentes.

Em outras palavras, a pergunta norteadora deste trabalho é: **Quais os locais mais afetados na cidade do Rio de Janeiro dentro das informações específicas coletadas sobre as dimensões espaciais, temporais e letais dos tiroteios ocorridos entre 2020 e 2025?** As perguntas específicas, dessa forma, são: (I) **Quais os locais com mais incidência de tiroteios?** (II) **Quais os locais com mais baixas de tiroteios?** (III) **Quais os locais com mais frequência de tiroteios?** Importante pontuar que a resposta esperada para este projeto não é um local único, mas o apontamento dos principais locais, a considerar as escalas de análise propostas.

Este trabalho foi realizado com a plataforma **Databricks Free Edition**, como recomendado pelos professores.

Importante pontuar que a base do Instituto Fogo Cruzado é **pública**, em cumprimento com a Lei Geral de Proteção de Dados, podendo ser utilizada por qualquer indivíduo ou organização para fins acadêmicos, profissionais ou políticos.

Carga dos Dados

Os dados utilizados para este trabalho foram coletados em 26/08/2026 por meio de uma requisição na API do site do Instituto Fogo Cruzado⁴, em formato .csv. O estado selecionado foi Rio de Janeiro, a cidade selecionada foi Rio de Janeiro, a data inicial dos dados foi definida como 01/01/2020 e a data final definida com 31/12/2025, contemplando a totalidade dos cinco anos do projeto. Ademais, o tipo das ocorrências consideradas contempla os tiroteios com e sem vítimas. Abaixo um print dos filtros definidos:

The screenshot shows the FOGOCRUZADO search interface. At the top, there are navigation links: PESQUISAR, DOCUMENTAÇÃO, and LOGIN. The main section is titled "Pesquisar ocorrências". It contains several filters: "Selecione o estado*" with a dropdown menu showing "Rio de Janeiro"; "Selecione a data inicial" with a date picker set to "01/01/2020"; "Selecione a data final" with a date picker set to "31/12/2025"; and "Selecione o tipo de ocorrência*" with a dropdown menu showing "Completo". Below these filters is a large orange "BUSCAR" button. Underneath the search button are two smaller orange buttons: "CSV" and "CSV DETALHADO". At the bottom, there is a table with columns: Id, Endereço, Região, Estado, Cidade, Bairro, Sub-bairro, Localidade, Latitude, Longitude, Data da Ocorrência, and Ação Policial. The first row of the table shows "Rua Tonelero".

Além disso, também foi utilizado uma base de dados espaciais sobre os bairros do Rio de Janeiro fornecida pelo DATA.Rio⁵ em formato .csv. A base não passou por nenhuma filtragem, de forma que todas as informações disponíveis foram coletadas.

The screenshot shows the DATA.RIO interface. On the left, there are options for transferring data: CSV, Shapefile, and GeoJSON. The main section displays a table with the following columns: Nome, Código do Bairro, Região Administrativa, Código da RA, Área de Planejamento, and Total. The table shows 25 lines of data out of 165 total. The first few rows are: Grumari (133, BARRA DA TIJUCA, 24, 4, 167), Jardim Sulacap (137, REALENGO, 33, 5, 13062), Saúde (001, PORTUARIA, 1, 1, 2749), Magalhães Bastos (138, REALENGO, 33, 5, 24430), Realengo (139, REALENGO, 33, 5, 18012), Sepetiba (150, SANTA CRUZ, 19, 5, 56575), Padre Miguel (140, BANGU, 17, 5, 64226), Senador Camará (142, BANGU, 17, 5, 10014), and Guaratiba (151, GUARATIBA, 26, 5, 10736).

⁴ Disponível em: <https://api.fogocruzado.org.br/search>

⁵ Disponível em: https://www.data.rio/datasets/fd354740f1934bf5bf8e9b0e2b509aa9_2/explore?location=-22.912995%2C-43.443313%2C0.00&showTable=true

Modelagem e Catálogo de Dados

Um esquema flat cumpriria o propósito para o trabalho, mas uma estrutura pouco mais complexa como o esquema estrela reduz a replicação de informações repetidas em cada linha. Por tal motivo, optei pela implementação deste esquema para a modelagem de dados.

Temos, de início, os seguintes catálogos de dados na íntegra, sem quaisquer modificações:

Número da Coluna	Nome da Coluna	Tipo do Dado	Descrição	Unidade	Valor Mínimo	Valor Máximo	Categorias	Linagem
1	nome	String	Nome do Bairro	N/A	N/A	N/A	"COPACABANA", "PRACA SECA", "GAVEA"	DATA.Rio
2	codbairro	String	Identificador único para cada Bairro	N/A	1	N/A	"1", "133", "84", "110"	DATA.Rio
3	regiao_adm	String	Nome da Região Administrativa	N/A	N/A	N/A	"BARRA DA TIJUCA", "REALENGO", "SANTA CRUZ"	DATA.Rio
4	codra	String	Identificador único para cada Região Administrativa	N/A	N/A	N/A	"1", "14", "24", "32"	DATA.Rio
5	area_plane	String	Nome da Área de Planejamento	N/A	1	N/A	"1", "2", "3", "4", "5"	DATA.Rio
6	Total_de_pessoas_2010	Float	Total da população em 2010	Habitantes	1	N/A	N/A	DATA.Rio
7	Total_de_pessoas_2022	Float	Total da população em 2022	Habitantes	1	N/A	N/A	DATA.Rio
8	diferenca_de_pessoas	Float	Diferença de população entre 2022 e 2010	Habitantes	1	N/A	N/A	DATA.Rio
9	Total_de_domicilios_2022	Float	Total de domicílios em 2022	Domicílios	1	N/A	N/A	DATA.Rio
10	Total_DP_2022	Float	Total de domicílios particulares em 2022	Domicílios	1	N/A	N/A	DATA.Rio
11	Total_DC	Float	Total de domicílios coletivos em 2022	Domicílios	1	N/A	N/A	DATA.Rio
12	Total_DP_Ocup_2010	Float	Total de Domicílios Particulares Ocupados em 2010	Domicílios	1	N/A	N/A	DATA.Rio
13	Total_DP_Ocup_2022	Float	Total de Domicílios Particulares Ocupados em 2022	Domicílios	1	N/A	N/A	DATA.Rio
14	diferenca_de_DP	Float	Diferença de Domicílios Particulares Ocupados entre 2022 e 2010	Domicílios	1	N/A	N/A	DATA.Rio
15	Shape_Length	Float	Tamanho do perímetro do Bairro	Metros	N/A	N/A	N/A	DATA.Rio
16	Shape_area	Float	Tamanho da área do Bairro	Metros quadrados	N/A	N/A	N/A	DATA.Rio

Em relação à base do DATA.Rio: Os valores mínimos e máximos foram definidos como 1 e N/A por não existir uma restrição de limite de população envolvida nestes dados. Seria possível inserir o valor máximo presente em cada coluna, mas para atualizações de dados futuros, esses valores máximos poderiam ser imprecisos e limitantes.

Número da Coluna	Nome da Coluna	Tipo do Dado	Descrição	Unidade	Valor Mínimo	Valor Máximo	Categorias	Linhagem
1	id	string	Identificador único da ocorrência	N/A	1	N/A	N/A	Instituto Fogo Cruzado
2	address	string	Endereço da ocorrência	N/A	N/A	N/A	"Rua Tonelero - Copacabana, Rio de Janeiro - RJ, Brasil", "Morro Santa Marta - Botafogo, Rio de Janeiro - RJ, 22260-126, Brasil", "Barão - Vila Kennedy - Bangu, Rio de Janeiro - RJ, 21850-007, Brasil"	Instituto Fogo Cruzado
3	region	string	Região da ocorrência	N/A	N/A	N/A	"Sudeste", "Nordeste"	Instituto Fogo Cruzado
4	state	string	Estado da ocorrência	N/A	N/A	N/A	"Rio de Janeiro", "Pernambuco", "Bahia"	Instituto Fogo Cruzado
5	city	string	Cidade da ocorrência	N/A	N/A	N/A	"Rio de Janeiro", "Belford Roxo", "Guapimirim", "Magé"	Instituto Fogo Cruzado
6	neighborhood	string	Bairro da ocorrência	N/A	N/A	N/A	"COPACABANA", "PRACA SECA", "GAVEA"	Instituto Fogo Cruzado
7	sub_neighborhood	string	Sub-bairro da ocorrência	N/A	N/A	N/A	"JARDIM NOVO", "RETA DA BASE", "AGUA GRANDE"	Instituto Fogo Cruzado
8	locality	string	Localidade específica da ocorrência	N/A	N/A	N/A	"TEIXEIRAS", "FAVELA BATEAU MOUCHE", "CATIRI"	Instituto Fogo Cruzado
9	latitude	float	Latitude do local da ocorrência	graus	N/A	N/A	N/A	Instituto Fogo Cruzado
10	longitude	float	Longitude do local da ocorrência	graus	N/A	N/A	N/A	Instituto Fogo Cruzado
11	data	timestamp	Data e hora da ocorrência	DD/MM/AAAA e HH:MM:SS	N/A	N/A	N/A	Instituto Fogo Cruzado
12	police_action	boolean	Indica se houve ação policial durante a ocorrência	N/A	N/A	N/A	"True", "False"	Instituto Fogo Cruzado
13	agent_presence	boolean	Indica se havia agentes de segurança presentes durante a ocorrência, dentro ou fora de serviço	N/A	N/A	N/A	"True", "False"	Instituto Fogo Cruzado
14	police_unit	string	Nome da unidade policial envolvida na ocorrência	Unidade Policial	N/A	N/A	"PM", "41 BPM, 31DP", "BOPE", "PF"	Instituto Fogo Cruzado
15	main_reason	string	Motivo principal da ocorrência	N/A	N/A	N/A	"Operação policial", "Ação policial", "Não identificado", "Tentativa/Roubo"	Instituto Fogo Cruzado
16	complementary_reason	string	Motivos complementares que contribuíram para a ocorrência	N/A	N/A	N/A	"Homicídio/Tentativa", "Operação policial", "Disputa"	Instituto Fogo Cruzado
17	clippings	string	Recortes relevantes relacionados à ocorrência	N/A	N/A	N/A	"Feminicídio/tentativa", "Ataques armados sobre rodas", "Bar", "Perseguição"	Instituto Fogo Cruzado
18	massacre	boolean	Indica se a ocorrência é classificada como uma chacina	N/A	N/A	N/A	"True", "False"	Instituto Fogo Cruzado
19	civilians_dead	int	Quantidade de civis mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
20	civilians_wounded	int	Quantidade de civis feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
21	agentes_dead	int	Quantidade de agentes mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
22	agentes_wounded	int	Quantidade de agentes feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
23	men_dead	int	Quantidade de homens mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
24	men_wounded	int	Quantidade de homens feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
25	women_dead	int	Quantidade de mulheres mortas na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
26	women_wounded	int	Quantidade de mulheres feridas na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
27	kids_dead	int	Quantidade de crianças mortas na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
28	kids_wounded	int	Quantidade de crianças feridas na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
29	teenagers_dead	int	Quantidade de adolescentes mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
30	teenagers_wounded	int	Quantidade de adolescentes feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
31	elderly_dead	int	Quantidade de idosos mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
32	elderly_wounded	int	Quantidade de idosos feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado

Em relação à base do Instituto Fogo Cruzado: Por ter sido coletada por meio de um API, as informações vieram filtradas apenas com informações sobre o município do Rio de Janeiro, então as colunas 3, 4 e 5 (region, state e city, respectivamente) apresentam valores semelhantes em todas as linhas; O API oferecia duas possibilidades de exportação de dados, de forma que a versão simplificada foi a escolhida por abranger as informações necessárias para a confecção deste projeto.

Um comentário que engloba ambas as bases é sobre as categorias apresentadas: estas apresentam exemplos possíveis de categorias, mas não a totalidade de possibilidades.

Com o objetivo de produzir um material enxuto de dados, foi realizada uma limpeza inicial antes de sua importação no Databricks por meio do programa Google Sheets. Algumas das colunas faltavam informações precisas ou apresentavam grandes vazios de dados, outras eram irrelevantes para a realização do projeto, por isso foram removidas. Como os arquivos originais foram preservados, a remoção dessas colunas não apresenta grandes problemas, visto que podem ser reintegradas ao


projeto, se necessário. Aproveitei para modificar o nome de algumas colunas e o nome dos arquivos a serem inseridos no databricks, como mostro nas tabelas abaixo:

Número da Coluna	Nome da Coluna	Tipo do Dado	Descrição	Unidade	Valor Mínimo	Valor Máximo	Categorias	Linhagem
1	COD_BAIRRO	String	Identificador único para cada Bairro	N/A	1	N/A	1, "133", "84", "110"	DATA.Rio
2	Nome_Bairro	String	Nome do Bairro	N/A	N/A	N/A	COPACABANA, "PRACA SECA", "GAVEA"	DATA.Rio
3	AP_Bairro	String	Nome da Área de Planejamento	N/A	1	N/A	1, "2", "3", "4", "5"	DATA.Rio
4	RP_Bairro	String	Nome da Região de Planejamento	N/A	1	N/A	1, "2", "3", "4", "5"	DATA.Rio
5	Total_Pop_Bairro_2022	Int	Total da população em 2022	Habitantes	1	N/A	N/A	DATA.Rio

Número da Coluna	Nome da Coluna	Tipo do Dado	Descrição	Unidade	Valor Mínimo	Valor Máximo	Categorias	Linhagem
1	Cod_Tiroteio	int	Identificador único da ocorrência	N/A	1	N/A	N/A	Instituto Fogo Cruzado
2	Endereco	string	Endereço da ocorrência	N/A	N/A	N/A	"Rua Tonelero - Copacabana, Rio de Janeiro - RJ, Brasil", "Morro Santa Marta - Botafogo, Rio de Janeiro - RJ, 22260-126, Brasil", "Barão - Vila Kennedy - Bangu, Rio de Janeiro - RJ, 21650-007, Brasil"	Instituto Fogo Cruzado
3	Cidade	string	Cidade da ocorrência	N/A	N/A	N/A	"Rio de Janeiro", "Belford Roxo", "Guapimirim", "Magé"	Instituto Fogo Cruzado
4	Nome_Bairro	string	Bairro da ocorrência	N/A	N/A	N/A	"COPACABANA", "PRACA SECA", "GAVEA"	Instituto Fogo Cruzado
5	Data	data	Data da ocorrência	Dia, mês, ano	01/01/2020	31/12/2025		Instituto Fogo Cruzado
6	Horario	string	Horário da ocorrência	Horas e minutos	00:00	23:59	N/A	Instituto Fogo Cruzado
7	Acao_Policial	boolean	Indica se havia agentes de segurança presentes durante a ocorrência, dentro ou fora de serviço	N/A	N/A	N/A	"True", "False"	Instituto Fogo Cruzado
8	Categoria_Tiroteio	string	Motivo principal da ocorrência	N/A	N/A	N/A	"Operação policial", "Ação policial", "Não identificado", "Tentativa/Roubo"	Instituto Fogo Cruzado
9	Civis_Mortos	int	Quantidade de civis mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
10	Civis_Feridos	int	Quantidade de civis feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
11	Agentes_Mortos	int	Quantidade de agentes mortos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
12	Agentes_Feridos	int	Quantidade de agentes feridos na ocorrência	Pessoas	0	N/A	N/A	Instituto Fogo Cruzado
13	Data_Horario	timestamp	Data e hora da ocorrência	DD/MM/AAAA e HH:MM:SS	N/A	N/A	N/A	Instituto Fogo Cruzado

Pipeline de Dados

Minha estratégia geral de modelagem consistiu, em termos gerais, (I) na limpeza de dados, (II) na checagem e padronização de informações, (III) na combinação das tabelas para a formação de um catálogo único, (IV) na nova rodada de checagem, (V) na produção de tabelas com dados modelados e agregados para resposta das perguntas propostas. Essa modelagem foi orientada por meio da arquitetura medalhão, com a transformação de dados da camada bronze até a camada gold, utilizando notebooks diferentes para cada etapa. À seguir, apresento o esquema estrela proposto à partir dos dados coletados previamente:



Para inicializar o processo do ETL na plataforma Databricks, foram realizados os seguintes passos:

1. Acessar o Databricks;
2. Clicar em “Data Ingestion” e criar um novo catálogo;
3. Clicar em “Create or Modify Table” para criar uma nova tabela;
4. Importar o CSV da base do Fogo Cruzado para dentro do Databricks File System (DBFS);
5. Selecionar o cluster;
6. Clicar em “Preview Table”;
7. Configurar os tipos de dados das colunas semelhante aos catálogos iniciais supracitados;
8. Clicar em “Create Table”;
9. Repetir todos os passos para a criação da tabela de dados do DATA.Rio;
10. Criar um novo Notebook e renomeá-lo para ‘Bronze_para_Prata’;

Com os dados devidamente ingeridos e com notebook criado, iniciei o processo de limpeza dos dados. Com a limpeza prévia de colunas, nenhum dado foi carregado com valor nulo ou vazio. A maioria dos dados carregados demonstraram consistência, mas a coluna ‘Data_Horario’ (formato timestamp) não estava no padrão esperado. Por tal motivo carreguei os dados como strings e os primeiros códigos feitos foram aplicados para solucionar essa questão:

Diagnóstico do formato timestamp na ‘tabela_tiroteios_bronze’

```
%sql
SELECT
  typeof(max(Data_Horario_Tiroteio)) AS original_type,
  'dd/MM/yyyy HH:mm:ss' AS detected_pattern,
  COUNT(*) AS total_rows,
  SUM(CASE WHEN to_timestamp(Data_Horario_Tiroteio, 'dd/MM/yyyy HH:mm:ss') IS NULL AND Data_Horario_Tiroteio IS NOT NULL THEN 1 ELSE 0 END) AS invalid_format_rows
FROM tabela_tiroteios_bronze;
```

> [See performance \(1\)](#) ✓ Checked for

Table	original_type	detected_pattern	total_rows	invalid_format_rows
1	string	dd/MM/yyyy HH:mm:ss	12638	0

Criação de tabela prata com timestamp adequado

```
%sql
CREATE OR REPLACE TABLE tabela_tiroteios_prata AS
SELECT
  * EXCEPT (Data_Horario_Tiroteio),
  to_timestamp(Data_Horario_Tiroteio, 'dd/MM/yyyy HH:mm:ss') AS Data_Horario_Tiroteio
FROM tabela_tiroteios_bronze;
```

> [See performance \(1\)](#)

Table	num_affected_rows	num_inserted_rows
No rows returned		

Validação dos timestamps convertidos

```
%sql
SELECT
  typeof(max(Data_Horario_Tiroteio)) AS converted_type,
  COUNT(*) AS total_rows,
  SUM(CASE WHEN Data_Horario_Tiroteio IS NULL THEN 1 ELSE 0 END) AS null_timestamps_after_conversion,
  MIN(Data_Horario_Tiroteio) AS min_timestamp,
  MAX(Data_Horario_Tiroteio) AS max_timestamp
FROM tabela_tiroteios_prata;
```

> [See performance \(1\)](#)

Table	converted_type	total_rows	null_timestamps_after_conversion	min_timestamp	max_timestamp
1	timestamp	12638	0	2019-12-31T21:01:00.000+00:...	2025-12-31T14:05:00.000+00:...

Também fiz checagens sobre possíveis duplicatas e sobre valores que poderiam estar fora do contexto, mas a base já se encontrava numa boa qualidade de limpeza e polidez dos dados, apenas com um pequeno problema de grafia de um dos bairros e uma incongruência devido aos dois bairros de nome freguesia presentes na cidade (um localizado na ilha do governador e o outro em jacarepaguá). Com as tabelas preparadas, o próximo passo foi a combinação e checagem das tabelas como preparação para o esquema de estrela e a correção dos problemas ortográficos:

Criação de tabela integrada e correção de dados

```
%sql
CREATE OR REPLACE TABLE workspace.default.tabela_tiroteios_bairros_prata AS
WITH bairros_normalized AS (
  SELECT
    Nome_Bairro,
    AP_Bairro,
    RA_Bairro,
    RP_Bairro,
    COD_BAIRRO,
    Total_Pop_Bairro_2022,
    upper(translate(trim(Nome_Bairro), 'AAAAAEEEEEEEEIIIOO000UUUC', 'AAAAEEEEEEEEIIIOO000UUUC')) AS bairro_key
  FROM workspace.default.tabela_bairros_bronze
),
-- Manual mapping for entries that cannot be matched automatically:
-- FREGUESIA (JACAREPAGUA) -> FREGUESIA in AP 4 (Zona Oeste / Jacarepagua)
-- FREGUESIA (ILHA) -> FREGUESIA in AP 3 (Ilha do Governador)
-- RICARDO DE ALBUQUERQUE -> RICARDO DE ALBUQUERQUE (typo in bairros table)
-- NI (nao identificado) -> left unmatched (no bairro equivalent)
manual_mapping AS (
  SELECT 'FREGUESIA (JACAREPAGUA)' AS tiroteio_nome, AP_Bairro, RP_Bairro, COD_BAIRRO, Total_Pop_Bairro_2022
  FROM workspace.default.tabela_bairros_bronze WHERE Nome_Bairro = 'FREGUESIA' AND AP_Bairro = 4
  UNION ALL
  SELECT 'FREGUESIA (ILHA)', AP_Bairro, RP_Bairro, COD_BAIRRO, Total_Pop_Bairro_2022
  FROM workspace.default.tabela_bairros_bronze WHERE Nome_Bairro = 'FREGUESIA' AND AP_Bairro = 3
  UNION ALL
  SELECT 'RICARDO DE ALBUQUERQUE', AP_Bairro, RP_Bairro, COD_BAIRRO, Total_Pop_Bairro_2022
  FROM workspace.default.tabela_bairros_bronze WHERE Nome_Bairro = 'RICARDO DE ALBUQUERQUE'
)
SELECT
  t.*,
  COALESCE(b.AP_Bairro, m.AP_Bairro) AS AP_Bairro,
  COALESCE(b.RP_Bairro, m.RP_Bairro) AS RP_Bairro,
  COALESCE(b.COD_BAIRRO, m.COD_BAIRRO) AS COD_BAIRRO,
  COALESCE(b.Total_Pop_Bairro_2022, m.Total_Pop_Bairro_2022) AS Total_Pop_Bairro_2022
FROM workspace.default.tabela_tiroteios_prata t
LEFT JOIN bairros_normalized b
  ON upper(translate(trim(t.Nome_Bairro), 'AAAAAEEEEEEEEIIIOO000UUUC', 'AAAAEEEEEEEEIIIOO000UUUC')) = b.bairro_key
LEFT JOIN manual_mapping m
  ON t.Nome_Bairro = m.tiroteio_nome
WHERE upper(trim(t.Nome_Bairro)) <> 'NI' OR t.Nome_Bairro IS NULL;
```

Validação da integração de tabelas

```
%sql -- validacao da tabela prata
SELECT
  (SELECT COUNT(*) FROM workspace.default.tabela_tiroteios_prata) AS base_rows,
  COUNT(*) AS merged_rows,
  SUM(CASE WHEN AP_Bairro IS NULL THEN 1 ELSE 0 END) AS rows_without_bairro_match,
  COUNT(DISTINCT Nome_Bairro) AS distinct_bairros_in_merged_table,
  COUNT(DISTINCT CASE WHEN AP_Bairro IS NULL THEN Nome_Bairro END) AS distinct_unmatched_bairros
FROM workspace.default.tabela_tiroteios_bairros_prata;
```

> [See performance \(1\)](#)

Table					
	1^2_3 base_rows	1^2_3 merged_rows	1^2_3 rows_without_bairro_match	1^2_3 distinct_bairros_in_merged_table	1^2_3 distinct_unmatched_bairros
1	12638	12634	0	159	0

Checagem de possíveis incongruências dos bairros

```
%sql -- checagem de possiveis bairros nao identificados
SELECT
  Nome_Bairro,
  COUNT(*) AS total_tiroteios,
  MIN(Data_Horario_Tiroteio) AS primeira_ocorrencia,
  MAX(Data_Horario_Tiroteio) AS ultima_ocorrencia
FROM workspace.default.tabela_tiroteios_bairros_prata
WHERE AP_Bairro IS NULL
  AND Nome_Bairro IS NOT NULL
GROUP BY Nome_Bairro
ORDER BY total_tiroteios DESC;
```

[See performance \(1\)](#)

Table		+	
A ^B C Nome_Bairro	1 ² total_tiroteios	📅 primeira_ocorrencia	📅 ultima_ocorrencia

No rows returned

Antes da produção dos dados agregados, produzi e validei novas colunas que indicassem separadamente os dias, meses e anos dos tiroteios para as análises futuras, assim como colunas sobre o somatório de mortos e de feridos.

Adicionar colunas de dia, mês e ano

```
1 %sql -- adicao colunas dia mes ano
2 ALTER TABLE workspace.default.tabela_tiroteios_bairros_prata
3 ADD COLUMNS (
4   Dia_Tiroteio INT,
5   Mes_Tiroteio INT,
6   Ano_Tiroteio INT
7 );
8
9 UPDATE workspace.default.tabela_tiroteios_bairros_prata
10 SET
11   Dia_Tiroteio = day(Data_Tiroteio),
12   Mes_Tiroteio = month(Data_Tiroteio),
13   Ano_Tiroteio = year(Data_Tiroteio);
```

> [See performance \(2\)](#)

Table	+
1	12636

Validar novas colunas derivadas de data

```
%sql -- validar novas colunas de dia mes ano
SELECT
  Data_Tiroteio,
  Dia_Tiroteio,
  Mes_Tiroteio,
  Ano_Tiroteio
FROM workspace.default.tabela_tiroteios_bairros_prata
WHERE Data_Tiroteio IS NOT NULL
ORDER BY Data_Tiroteio
LIMIT 25;
```

> [See performance \(1\)](#)

	📅 Data_Tiroteio	¹ ₃ Dia_Tiroteio	¹ ₃ Mes_Tiroteio	¹ ₃ Ano_Tiroteio
11	2020-01-04	4	1	2020
12	2020-01-04	4	1	2020
13	2020-01-04	4	1	2020
14	2020-01-04	4	1	2020
15	2020-01-04	4	1	2020
16	2020-01-04	4	1	2020
17	2020-01-05	5	1	2020
18	2020-01-05	5	1	2020

Adicionar colunas de trimestre e semestre

```
1 %sql -- adicao colunas trimestre e semestre
2 ALTER TABLE workspace.default.tabela_tiroteios_bairros_prata
3 ADD COLUMNS (
4   trimestre INT,
5   semestre INT
6 );
7
8 UPDATE workspace.default.tabela_tiroteios_bairros_prata
9 SET
10   trimestre = quarter(Data_Tiroteio),
11   semestre = CASE
12     WHEN month(Data_Tiroteio) BETWEEN 1 AND 6 THEN 1
13     WHEN month(Data_Tiroteio) BETWEEN 7 AND 12 THEN 2
14     ELSE NULL
15   END;
```

	Table	+
	¹ ₃ num_affected_rows	
1	12634	

Validar colunas de trimestre e semestre

```
%sql
SELECT
  Data_Tiroteio,
  Mes_Tiroteio,
  trimestre,
  semestre
FROM workspace.default.tabela_tiroteios_bairros_prata
WHERE Data_Tiroteio IS NOT NULL
ORDER BY Data_Tiroteio
LIMIT 500;
```

> [See performance \(1\)](#)

	📅 Data_Tiroteio	1 ² Mes_Tiroteio	1 ² trimestre	1 ² semestre
420	2020-02-19	2	1	1
421	2020-02-19	2	1	1
422	2020-02-19	2	1	1
423	2020-02-19	2	1	1
424	2020-02-19	2	1	1
425	2020-02-19	2	1	1
426	2020-02-19	2	1	1
427	2020-02-19	2	1	1
428	2020-02-19	2	1	1
429	2020-02-19	2	1	1
430	2020-02-19	2	1	1
431	2020-02-20	2	1	1
432	2020-02-20	2	1	1

Esse processo apresentou duas linhas cujo ano da ocorrência apontava o valor 2019, provavelmente devido ao formato timestamp, ou talvez por causa da duração do tiroteio (que pode ter tido início no dia 31 de dezembro de 2019, durando até 1 de janeiro de 2020). Estes dados foram excluídos, como mostram os códigos a seguir:

Deletar dados fora da janela temporal de análise

```
%sql
DELETE FROM workspace.default.tabela_tiroteios_bairros_prata
WHERE Ano_Tiroteio = 2019;
```

> [See performance \(1\)](#)

	1 ² num_affected_rows
1	2

Checagem final de dados fora da janela temporal de análise

```
%sql
SELECT
  COUNT(*) AS remaining_2019_rows,
  MIN(Data_Tiroteio) AS min_remaining_date,
  MAX(Data_Tiroteio) AS max_remaining_date,
  COUNT(*) FILTER (WHERE Ano_Tiroteio IS NULL) AS null_year_rows,
  COUNT(*) AS total_rows_checked
FROM workspace.default.tabela_tiroteios_bairros_prata
WHERE Ano_Tiroteio = 2019 OR Ano_Tiroteio IS NULL;
```

> [See performance \(1\)](#) ✓ Checked for improvements

Table	remaining_2019_rows	min_remaining_date	max_remaining_date	null_year_rows	total_rows_checked
1	0	null	null	0	

Com todas as colunas devidamente criadas, limpas e uniformizadas, criei um segundo notebook chamado 'Prata_para_Ouro', onde terminei de estruturar os dados no esquema estrela apresentado previamente:

Criação das tabelas dimensionais e fato

```
4 minutes ago (15s)

%sql
CREATE TABLE workspace.default.DIM_Territorio AS
WITH territorio_base AS (
  SELECT DISTINCT
    COD_BAIRRO,
    Nome_Bairro,
    AP_Bairro,
    RP_Bairro,
    Cidade,
    Total_Pop_Bairro_2022
  FROM workspace.default.tabela_tiroteios_bairros_prata
)
SELECT
  ROW_NUMBER() OVER (
    ORDER BY COD_BAIRRO, Nome_Bairro, AP_Bairro, RP_Bairro, Cidade, Total_Pop_Bairro_2022
  ) AS id_territorio,
  COD_BAIRRO,
  Nome_Bairro,
  AP_Bairro,
  RP_Bairro,
  Cidade,
  Total_Pop_Bairro_2022
FROM territorio_base;

CREATE TABLE workspace.default.DIM_Tempo AS
WITH tempo_base AS (
  SELECT DISTINCT
    Data_Tiroteio,
    Horário_Tiroteio,
    Dia_Tiroteio,
    Mes_Tiroteio,
    Ano_Tiroteio,
    semestre,
    trimestre
  FROM workspace.default.tabela_tiroteios_bairros_prata
)
SELECT
  ROW_NUMBER() OVER (
    ORDER BY Data_Tiroteio, Horário_Tiroteio, Dia_Tiroteio, Mes_Tiroteio, Ano_Tiroteio, semestre, trimestre
  ) AS id_tempo,
  Data_Tiroteio,
  Horário_Tiroteio AS Horário__Tiroteio,
  Dia_Tiroteio,
  Mes_Tiroteio,
  Ano_Tiroteio,
  semestre,
  trimestre
FROM tempo_base;
```

```

CREATE TABLE workspace.default.DIM_Tipo_Evento AS
WITH tipo_evento_base AS (
  SELECT DISTINCT
    Acao_Policial_Tiroteio,
    Categoria_Tiroteio
  FROM workspace.default.tabela_tiroteios_bairros_prata
)
SELECT
  ROW_NUMBER() OVER (
    ORDER BY Acao_Policial_Tiroteio, Categoria_Tiroteio
  ) AS id_tipo_evento,
  Acao_Policial_Tiroteio AS Acao_policial_Tiroteio,
  Categoria_Tiroteio
FROM tipo_evento_base;

CREATE TABLE workspace.default.Fato_Tiroteio AS
SELECT
  s.Cod_Tiroteio,
  s.Endereco_Tiroteio,
  s.Civis_Mortos_Tiroteio,
  s.Civis_Feridos_Tiroteios AS Civis_Feridos_Tiroteio,
  s.Agentes_Mortos_Tiroteio,
  s.Agentes_Feridos_Tiroteio,
  dt.id_territorio,
  dtmp.id_tempo,
  dte.id_tipo_evento
FROM workspace.default.tabela_tiroteios_bairros_prata AS s
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON s.COD_BAIRRO <=> dt.COD_BAIRRO
 AND s.Nome_Bairro <=> dt.Nome_Bairro
 AND s.AP_Bairro <=> dt.AP_Bairro
 AND s.RP_Bairro <=> dt.RP_Bairro
 AND s.Cidade <=> dt.Cidade
 AND s.Total_Pop_Bairro_2022 <=> dt.Total_Pop_Bairro_2022
INNER JOIN workspace.default.DIM_Tempo AS dtmp
  ON s.Data_Tiroteio <=> dtmp.Data_Tiroteio
 AND s.Horario_Tiroteio <=> dtmp.Horario_Tiroteio
 AND s.Dia_Tiroteio <=> dtmp.Dia_Tiroteio
 AND s.Mes_Tiroteio <=> dtmp.Mes_Tiroteio
 AND s.Ano_Tiroteio <=> dtmp.Ano_Tiroteio
 AND s.semestre <=> dtmp.semestre
 AND s.trimestre <=> dtmp.trimestre
INNER JOIN workspace.default.DIM_Tipo_Evento AS dte
  ON s.Acao_Policial_Tiroteio <=> dte.Acao_policial_Tiroteio
 AND s.Categoria_Tiroteio <=> dte.Categoria_Tiroteio;

```

Mais uma etapa de validações, de chaves e de dados:

Validar contagens das novas tabelas

```

%sql
SELECT 'workspace.default.tabela_tiroteios_bairros_prata' AS tabela, COUNT(*) AS quantidade_registros
FROM workspace.default.tabela_tiroteios_bairros_prata
UNION ALL
SELECT 'workspace.default.DIM_Territorio' AS tabela, COUNT(*) AS quantidade_registros
FROM workspace.default.DIM_Territorio
UNION ALL
SELECT 'workspace.default.DIM_Tempo' AS tabela, COUNT(*) AS quantidade_registros
FROM workspace.default.DIM_Tempo
UNION ALL
SELECT 'workspace.default.DIM_Tipo_Evento' AS tabela, COUNT(*) AS quantidade_registros
FROM workspace.default.DIM_Tipo_Evento
UNION ALL
SELECT 'workspace.default.Fato_Tiroteio' AS tabela, COUNT(*) AS quantidade_registros
FROM workspace.default.Fato_Tiroteio;

```

> [See performance \(1\)](#)

Table ▼ +		
	A^0_{C} tabela	s^0_{Q} quantidade_registros
1	workspace.default.tabela_tiroteios_bairros_pra...	12634
2	workspace.default.DIM_Territorio	159
3	workspace.default.DIM_Tempo	12437
4	workspace.default.DIM_Tipo_Evento	27
5	workspace.default.Fato_Tiroteio	12634

Validar chaves e amostra do fato

```
%sql
SELECT
    f.Cod_Tiroteio,
    f.id_territorio,
    f.id_tempo,
    f.id_tipo_evento,
    dt.Nome_Bairro,
    dtmp.Data_Tiroteio,
    dtmp.Horario__Tiroteio,
    dte.Categoria_Tiroteio
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
    ON f.id_territorio = dt.id_territorio
INNER JOIN workspace.default.DIM_Tempo AS dtmp
    ON f.id_tempo = dtmp.id_tempo
INNER JOIN workspace.default.DIM_Tipo_Evento AS dte
    ON f.id_tipo_evento = dte.id_tipo_evento
ORDER BY f.Cod_Tiroteio
LIMIT 5;
```

> [See performance \(1\)](#)

	id Cod_Tiroteio	id id_territorio	id id_tempo	id id_tipo_evento	Nome_Bairro	Data_Tiroteio	Horario_Tiroteio	Categoria_Tiroteio
1	32852	99	1	7	PENHA	2020-01-01	13:30:00	Não identificado
2	32853	132	3	7	VICENTE DE CARVALHO	2020-01-01	15:14:00	Não identificado
3	32854	99	2	7	PENHA	2020-01-01	15:12:00	Não identificado
4	32855	146	4	7	ROCHA MIRANDA	2020-01-01	16:00:00	Não identificado
5	32856	50	5	7	INHOAIBA	2020-01-01	22:26:00	Não identificado

Com as bases devidamente montadas, agora é possível dar início às análises.

Qualidade de Dados

Os dados foram coletados em ótima qualidade, com poucas alterações efetivamente realizadas. Os nomes e os tipos das colunas eram condizentes com todos os metadados apresentados, o que tornou a coleta um processo acessível de se realizar. Os únicos problemas que precisaram ser resolvidos foram o formato timestamp que precisou ser inserido como string e posteriormente dissecado em outras colunas, assim como alguns erros de digitação presentes no nome de alguns bairros.

Foram realizadas checagens e validações após todas as etapas de alteração, de forma que todas as categorias e dados consistentes se mantiveram até o final do pipeline.

Existiram possibilidades de alteração de tipos de dados, como por exemplo a coluna 'codbairro' (DATA.Rio), que foi coletada como string e que poderia ser alterada para int por possuir apenas números na sua composição, mas optei por manter no formato original, principalmente pela conformidade com o padrão de outras bases públicas.

Análise de Dados

Com o banco de dados devidamente estruturado, iniciei a etapa de análise de dados à partir das perguntas específicas de forma orientada à pergunta norteadora do trabalho: **Dentro das informações específicas coletadas sobre as dimensões espaciais, temporais e letais dos tiroteios ocorridos na cidade do Rio de Janeiro entre 2020 e 2025, quais os locais mais afetados, para cada dimensão analisada?**

Quais os locais com mais incidência de tiroteios?

Inicialmente fiz uma query na base de dados para descobrir um panorama geral de tiroteios e de sua distribuição geral pelos bairros e pelos anos.

Total de tiroteios

```
%sql --name total_tiroteios
SELECT COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio;
```

> [See performance \(1\)](#)

Table ▾		+
	¹ ₃ total_tiroteios	
1	12634	

Distribuição de tiroteios ao longo do ano

```
%sql --name distribuicao_ano
SELECT
    dtmp.Ano_Tiroteio,
    COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Tempo AS dtmp
    ON f.id_tempo = dtmp.id_tempo
GROUP BY dtmp.Ano_Tiroteio
ORDER BY dtmp.Ano_Tiroteio;
```

> [See performance \(1\)](#)

Table ▾		+
	¹ ₃ Ano_Tiroteio	¹ ₃ total_tiroteios
1	2020	2724
2	2021	2503
3	2022	2175
4	2023	1974
5	2024	1691
6	2025	1567

Distribuição de tiroteios por bairro

```
%sql --name distribuicao_bairros
SELECT
  dt.Nome_Bairro,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.Nome_Bairro
ORDER BY total_tiroteios DESC, dt.Nome_Bairro;
```

> [See performance \(1\)](#)

Table  

	^A _c Nome_Bairro	¹ ₃ total_tiroteios
1	VILA KENNEDY	674
2	PRACA SECA	504
3	MARE	365
4	VILA ISABEL	363
5	BANGU	357
6	CASCADURA	330
7	TIJUCA	327
8	VICENTE DE CARVALHO	322
9	CIDADE DE DEUS	312
10	COSTA BARROS	299

Agora, sabemos que temos um total de **12634 tiroteios** na base, distribuídos em seis anos, tendo Vila Kennedy isoladamente com o maior número geral de tiroteios (674), seguido de Praça Seca (504), Maré (365), Vila Isabel (363) e Bangu (357). Essa primeira rodada de queries já serve para responder a primeira pergunta específica, mas apenas na escala de bairro. Como tiroteios são um reflexo de diversas tensões que envolvem grupos criminosos e forças armadas, diferentes escalas de análise podem apresentar outras dimensões desses conflitos.

Em seguida, realizei uma segunda rodada de queries para descobrir quais as RPs (regiões de planejamento) e as APs (áreas de planejamento) com mais incidência de tiroteios.

Distribuição de tiroteios por área de planejamento

```
%sql --name distribuicao_AP
SELECT
  dt.AP_Bairro,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.AP_Bairro
ORDER BY total_tiroteios DESC, dt.AP_Bairro;
```

> [See performance \(1\)](#)

	AP_Bairro	total_tiroteios
1	3	6321
2	5	2135
3	4	1948
4	2	1402
5	1	828

Distribuição de tiroteios por região de planejamento

```
%sql --name distribuicao_RP
SELECT
  dt.RP_Bairro,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.RP_Bairro
ORDER BY total_tiroteios DESC, dt.RP_Bairro;
```

> [See performance \(1\)](#)

	RP_Bairro	total_tiroteios
1	3.3	1847
2	5.1	1627
3	4.1	1552
4	3.6	1115
5	3.5	1027
6	2.2	1023
7	3.2	916
8	1.1	828
9	3.1	678
10	3.4	530
11	4.2	396
12	2.1	379
13	5.2	244
14	3.7	208
15	5.3	205

Com as novas informações, vemos que a AP 3 possui a maior quantidade de tiroteios do município, com 6321 ocorrências, quase o triplo de ocorrências da AP 5 (2135), que está em segundo lugar. Na escala de RPs, o resultado se mostra mais

distribuído, com a RP 3.3 com o maior número de ocorrências (1847), seguida das RPs 5.1 (1627) e 4.1 (1552). Esses dados nos apresentam a complexidade de uma análise multiescalar: as diferentes escalas apresentam informações que, isoladamente, não capturam com totalidade o complexo contexto da violência na cidade do Rio de Janeiro.

Respondendo a primeira pergunta, **os locais com mais incidência de tiroteios** na escala das APs é isoladamente a **AP 3⁶**, com **6321 ocorrências (50% do total)** neste período. Na escala das RPs, de forma mais homogênea, temos a **RP 3.3⁷** (1847, 14,6%), seguida das **RPs 5.1** (1627, 12,8%), **4.1** (1552, 12,3%), **3.6** (1115, 8,8%) e **3.5** (1027, 8,1%), demonstrando que embora exista um inchaço de tiroteios na AP 3, as APs 4⁸ e 5⁹ também possuem presença considerável de ocorrências. Na escala dos bairros, temos **Vila Kennedy** (AP 5, RP 5.1, 674, 5,3%), seguido de **Praça Seca** (AP 4, RP 4.1, 504, 3,9%), **Maré** (AP 3, RP 3.1, 365, 2,8%), **Vila Isabel** (AP 2, RP 2.2, 363, 2,8%) e **Bangu** (AP 5, RP 5.1, 357, 2,8%).

Quais os locais com mais baixas de tiroteios?

É de se esperar que a AP 3 apresente a maior quantidade de baixas de tiroteios, mas é possível que a quantidade e a letalidade não sejam necessariamente convergentes. Fiz uma query para compreender como as **2,471 baixas de civis e as 211 baixas de agentes** se distribuem no território.

⁶ A AP 3 é composta pelos bairros da zona norte do Rio de Janeiro, desconsiderando os bairros da Grande Tijuca, que pertencem à AP 2 (zona sul).

⁷ Os bairros que compõem a RP 3.3 são: Colégio, Irajá, Vicente de Carvalho, Vila da Penha, Vila Kosmos, Vista Alegre, Bento Ribeiro, Campinho, Cavalcanti, Engenheiro Leal, Honório Gurgel, Madureira, Marechal Hermes, Osvaldo Cruz, Quintino Bocaiúva, Rocha Miranda, Turiaçu e Vaz Lobo.

⁸ A AP 4 é composta pelos bairros da recém criada zona sudoeste do Rio de Janeiro, com faixa de território entre Praça Seca e Recreio dos Bandeirantes.

⁹ A AP 5 é composta pelos bairros remanescentes da zona oeste do Rio de Janeiro.

Distribuição de baixas de civis e tiroteios por bairro

```
%sql --name civis_mortos_por_regiao
SELECT
  dt.RP_Bairro,
  dt.Nome_Bairro,
  SUM(COALESCE(f.Civis_Mortos_Tiroteio, 0)) AS total_civis_mortos,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.RP_Bairro, dt.Nome_Bairro
ORDER BY total_civis_mortos DESC, total_tiroteios DESC, dt.RP_Bairro, dt.Nome_Bairro;
```

> [See performance \(1\)](#)

Table  

	^B _C RP_Bairro	^B _C Nome_Bairro	² ₃ total_civis_mortos	² ₃ total_tiroteios
1	3.5	PENHA	198	226
2	3.1	MARE	91	365
3	5.1	BANGU	82	357
4	3.3	VICENTE DE CARVALHO	68	322
5	5.3	SANTA CRUZ	66	143
6	5.1	VILA KENNEDY	63	674
7	3.6	COSTA BARROS	61	299
8	4.1	PRACA SECA	58	504
9	3.3	CASCADURA	56	330
10	5.1	REALENGO	51	271
11	4.2	RECREIO DOS BANDEIRANT...	50	93
12	3.3	MADUREIRA	48	294
13	5.1	SENADOR CAMARA	47	141
14	3.4	COMPLEXO DO ALEMAO	45	298
15	4.1	GARDENIA AZUL	45	100

Decerto, a quantidade de tiroteios apresenta certa correlação com letalidade, mas também apresenta bairros diferentes das queries anteriores. Dos cinco bairros com maior quantidade histórica de tiroteios, apenas dois reaparecem na lista de bairros com maior quantidade de baixas de **civis**: Maré (segundo lugar) e Bangu (terceiro lugar), com 91 e 82 baixas, respectivamente. Como novidades, temos **Penha** (AP 3, RP 3.5, 198 baixas) em primeiro lugar, **Vicente de Carvalho** (AP 3, RP 3.3, 68) em quarto e **Santa Cruz** (AP 5, RP 5.3, 66) em quinto. Por AP e por RP, os números não saem muito do esperado:

Distribuição de baixas de civis e tiroteios por área de planejamento

```
%sql --name civis_mortos_por_ap
SELECT
  dt.AP_Bairro,
  SUM(COALESCE(f.Civis_Mortos_Tiroteio, 0)) AS total_civis_mortos,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.AP_Bairro
ORDER BY total_civis_mortos DESC, total_tiroteios DESC, dt.AP_Bairro;
```

> [See performance \(1\)](#)

	A ^B _C AP_Bairro	1 ² ₃ total_civis_mortos	1 ² ₃ total_tiroteios
1	3	1261	6321
2	5	458	2135
3	4	456	1948
4	2	156	1402
5	1	140	828

Distribuição de baixas de civis e tiroteios por região de planejamento

```
%sql --name civis_mortos_por_rp
SELECT
  dt.RP_Bairro,
  SUM(COALESCE(f.Civis_Mortos_Tiroteio, 0)) AS total_civis_mortos,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.RP_Bairro
ORDER BY total_civis_mortos DESC, total_tiroteios DESC, dt.RP_Bairro;
```

> [See performance \(1\)](#)

	A ^B _C RP_Bairro	1 ² ₃ total_civis_mortos	1 ² ₃ total_tiroteios
1	3.3	341	1847
2	4.1	305	1552
3	3.5	305	1027
4	5.1	279	1627
5	3.6	225	1115
6	4.2	151	396
7	3.2	143	916
8	3.1	143	678
9	1.1	140	828
10	2.2	103	1023

As APs seguem o mesmo padrão do total de tiroteios no total de civis mortos: AP 3 com maior volume de ocorrências, seguido da AP 5 e 4. Na escala das RPs, as cinco principais regiões se mantêm, apenas com alterações em suas posições: RP 3.3 continua no topo, com a RP 4.1 em segundo lugar, 3.5 em terceiro, 5.1 em quarto e 3.6 em quinto.

Distribuição de baixas de agentes e tiroteios por bairro

```
%sql --name agentes_mortos_por_regiao
SELECT
  dt.RP_Bairro,
  dt.Nome_Bairro,
  SUM(COALESCE(f.Agentes_Mortos_Tiroteio, 0)) AS total_agentes_mortos,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
GROUP BY dt.RP_Bairro, dt.Nome_Bairro
ORDER BY total_agentes_mortos DESC, total_tiroteios DESC, dt.RP_Bairro, dt.Nome_Bairro;
```

> [See performance \(1\)](#)

	A ^B _C RP_Bairro	A ^B _C Nome_Bairro	1 ² ₃ total_agentes_mortos	1 ² ₃ total_tiroteios
1	5.1	BANGU	14	357
2	5.2	CAMPO GRANDE	10	146
3	5.1	REALENGO	9	271
4	3.6	GUADALUPE	8	165
5	5.3	SANTA CRUZ	8	143
6	3.5	PENHA	7	226
7	4.2	RECREIO DOS BANDEIRANT...	7	93
8	4.2	BARRA DA TIJUCA	7	77
9	3.3	IRAJA	6	103
10	3.5	VIGARIO GERAL	5	97
11	3.1	MARE	4	365
12	4.1	CIDADE DE DEUS	4	312
13	3.5	CORDOVIL	4	221
14	3.6	ANCHIETA	4	209

No que tange os agentes mortos, o horizonte de dados é muito menor, tendo 14 como o maior número de baixas da categoria. Um fato curioso é que, desconsiderando o bairro Bangu da lista, os outros quatro bairros com maior quantidade de mortes de agentes não haviam aparecido com tanta relevância nas queries anteriores, o que pode inclusive ser argumento para um número menor de tiroteios nesses locais. São lugares que se mostram mais violentos para a polícia mas, com uma quantidade pouco substancial de dados, se torna uma afirmativa fraca e pouco consistente.

Então, **os locais com mais baixas de tiroteios** na escala de APs é a **AP 3**, com 51% (1261) das baixas dos civis. Nas RPs, temos as **RPs 3.3** (341, 13,8%), **4.1** (305, 12,3%) **3.5** (305, 12,3%), **5.1** (279, 11,2%) e **3.6** (225, 9,1%). Nos bairros, temos **Penha** (AP 3, RP 3.5, 198, 8%) , **Maré** (AP 3, RP 3.1, 91, 3,6%), **Bangu** (AP 5, RP 5.1, 82, 3,3%), **Vicente de Carvalho** (AP 3, RP 3.3, 68, 2,7%) e **Santa Cruz** (AP 5, RP 5.3, 66, 2,6%).

Quais os locais com mais frequência de tiroteios?

Como vimos anteriormente na segunda query realizada, temos uma distribuição de informações que mostra uma certa tendência decrescente na quantidade de ocorrências, com 2724 tiroteios em 2020, chegando aos 1567 em 2025. Em seguida, realizei novos queries para entender como esses valores se distribuem por trimestre e semestre, para investigar se existe algum possível padrão.

	¹ ₂ Ano_Tiroteio	¹ ₂ total_tiroteios
1	2020	2724
2	2021	2503
3	2022	2175
4	2023	1974
5	2024	1691
6	2025	1567

Distribuição de tiroteios por ano, semestre e trimestre


```
%sql --name distribuicao_trimestre_semestre
SELECT
    dtmp.Ano_Tiroteio,
    dtmp.semestre,
    dtmp.trimestre,
    COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Tempo AS dtmp
    ON f.id_tempo = dtmp.id_tempo
GROUP BY dtmp.Ano_Tiroteio, dtmp.semestre, dtmp.trimestre
ORDER BY dtmp.Ano_Tiroteio, dtmp.semestre, dtmp.trimestre;
```

> [See performance \(1\)](#)

Table  

	¹ ₂ Ano_Tiroteio	¹ ₂ semestre	¹ ₂ trimestre	¹ ₂ total_tiroteios
1	2020	1	1	771
2	2020	1	2	796
3	2020	2	3	580
4	2020	2	4	577
5	2021	1	1	798
6	2021	1	2	754
7	2021	2	3	530
8	2021	2	4	421
9	2022	1	1	493
10	2022	1	2	595
11	2022	2	3	593
12	2022	2	4	494
13	2023	1	1	619

Para facilitar a visualização, exportei os dados para o google sheets para construir uma planilha simplificada de distribuição por trimestre com o objetivo de produzir um gráfico que pudesse demonstrar algum padrão. o resultado demonstra um inchaço principal de ocorrências no **primeiro semestre** e, de forma mais específica, no **segundo trimestre** do ano.



Realizei uma nova query para avaliar a distribuição dos tiroteios ao longo dos anos por bairro, de forma a investigar se os bairros que mais apareceram nas outras perguntas específicas mantêm o protagonismo nessa dimensão.


Distribuição de tiroteios por bairro e ano

```
%sql --name distribuicao_bairro_ano
SELECT
  dt.Nome_Bairro,
  dtmp.Ano_Tiroteio,
  COUNT(*) AS total_tiroteios
FROM workspace.default.Fato_Tiroteio AS f
INNER JOIN workspace.default.DIM_Territorio AS dt
  ON f.id_territorio = dt.id_territorio
INNER JOIN workspace.default.DIM_Tempo AS dtmp
  ON f.id_tempo = dtmp.id_tempo
GROUP BY dt.Nome_Bairro, dtmp.Ano_Tiroteio
ORDER BY dt.Nome_Bairro, dtmp.Ano_Tiroteio;
```

> [See performance \(1\)](#)

Table  

	^A _C Nome_Bairro	¹ ₃ Ano_Tiroteio	¹ ₃ total_tiroteios
694	SAUDE	2020	1
695	SAUDE	2021	1
696	SAUDE	2023	1
697	SAUDE	2025	1
698	SENADOR CAMARA	2020	35
699	SENADOR CAMARA	2021	39
700	SENADOR CAMARA	2022	27
701	SENADOR CAMARA	2023	23
702	SENADOR CAMARA	2024	10
703	SENADOR CAMARA	2025	7
704	> SENADOR VASCO...	2020	2
705	> SENADOR VASCO...	2022	1
706	> SENADOR VASCO...	2025	1



Avaliando o ciclo de anos dos oito bairros apontados nas buscas pelas respostas às perguntas específicas anteriores, percebe-se que existem diferentes padrões de ocorrências entre eles, com os bairros de **Vila Kennedy** e **Praça Seca** destoando das demais, com períodos pontuais de altas elevadas de tiroteios. Vila Kennedy, inclusive, apresenta o ano com o maior número histórico de tiroteios: 319 ocorrências no ano de 2020.

Avaliando os 10 locais com mais tiroteios por ano, bairros como **Cidade de Deus**, **Tijuca**, **Cascadura** e **Complexo do Alemão** também aparecem, resultado esperado ao considerar que os quatro se encontram dentro dos 11 bairros com mais tiroteios na cidade.

Realizei uma última query para comparar os bairros com mais tiroteios em 2020 e 2025 e constatei que **dentre os 10 bairros com mais tiroteios em 2025, apenas quatro se mantêm dentro do intervalo**. Destes quatro, 3 subiram de posição. Além disso, todos os bairros (menos Vicente de Carvalho) passaram por uma redução do número de tiroteios.

Comparativo de tiroteios por bairro, 2020 e 2025

```
%sql --name comparativo_2020_vs_2025
WITH base AS (
  SELECT
    dt.Nome_Bairro,
    dtmp.Ano_Tiroteio,
    COUNT(*) AS total_tiroteios
  FROM workspace.default.Fato_Tiroteio AS f
  INNER JOIN workspace.default.DIM_Territorio AS dt
    ON f.id_territorio = dt.id_territorio
  INNER JOIN workspace.default.DIM_Tempo AS dtmp
    ON f.id_tempo = dtmp.id_tempo
  WHERE dtmp.Ano_Tiroteio IN (2020, 2025)
  GROUP BY dt.Nome_Bairro, dtmp.Ano_Tiroteio
)
SELECT
  Nome_Bairro,
  MAX(CASE WHEN Ano_Tiroteio = 2020 THEN total_tiroteios ELSE 0 END) AS tiroteios_2020,
  MAX(CASE WHEN Ano_Tiroteio = 2025 THEN total_tiroteios ELSE 0 END) AS tiroteios_2025,
  MAX(CASE WHEN Ano_Tiroteio = 2025 THEN total_tiroteios ELSE 0 END) -
  MAX(CASE WHEN Ano_Tiroteio = 2020 THEN total_tiroteios ELSE 0 END) AS variacao,
  RANK() OVER (ORDER BY MAX(CASE WHEN Ano_Tiroteio = 2020 THEN total_tiroteios ELSE 0 END) DESC, Nome_Bairro) AS rank_2020,
  RANK() OVER (ORDER BY MAX(CASE WHEN Ano_Tiroteio = 2025 THEN total_tiroteios ELSE 0 END) DESC, Nome_Bairro) AS rank_2025
FROM base
GROUP BY Nome_Bairro
ORDER BY tiroteios_2020 DESC, Nome_Bairro;
```

Logo, os **locais com mais frequência de tiroteios** são praticamente os mesmos locais com a maior quantidade de tiroteios. Essa resposta não sai do esperado, mas são as granularidades que aprofundam a dimensão analisada: (I) o número geral de tiroteios está **decrecendo** desde 2020, com queda de aproximadamente 43% comparado com 2025; (II) a maioria dos tiroteios ocorrem nos **primeiros semestres** dos anos, mais especificamente nos **segundos trimestres** e; (III) o volume de tiroteios não é um reflexo direto de violências constantes, podendo apresentar **momentos ou crescentes pontuais de conflitos** em diferentes territórios.

Com o conjunto de informações levantadas perante as três perguntas específicas, é possível responder a pergunta de partida.

Quais os locais mais afetados na cidade do Rio de Janeiro dentro das informações específicas coletadas sobre as dimensões espaciais, temporais e letais dos tiroteios ocorridos entre 2020 e 2025?

Na escala de **Área de Planejamento**, o local mais afetado é a **AP 3**, com a maior quantidade de ocorrências (6321 tiroteios, 50% do total) e baixas de civis (1261, 51% do total).

Na escala de **Região de Planejamento**, temos a **RP 3.3** com a maior quantidade de ocorrências (1847, tiroteios, 14,6% do total) e baixas de civis (341, 13,8% do total). As RPs 3.5 (1027 tiroteios, 305 baixas), 5.1 (1627 tiroteios, 279 baixas) e 3.6 (1115 tiroteios, 225 baixas) também valem ser mencionadas pelos seus valores substanciais.

Na escala de **bairro** existe uma clara convergência entre baixas e tiroteios: **Vila Kennedy** é o lugar com a maior quantidade de tiroteios (674), ocupando o sexto lugar na quantidade de baixas (63). **Penha** é um local que foge do padrão, com 226 tiroteios (15º lugar da cidade), mas com 8% (198) das baixas de civis, maior valor da base. Além desses dois lugares, Praça Seca, Maré, Bangu, Vicente de Carvalho, Vila Isabel e Santa Cruz também apresentam altos valores de tiroteios e baixas, como apresentado na tabela abaixo. Bairros como Tijuca, Cidade de Deus, Cascadura e Complexo do Alemão também apareceram nas queries, mas apenas quando a dimensão do tempo foi acionada.

Bairro	Total de Tiroteios	Total de Baixas de Civis
VILA KENNEDY	674	63
PRAÇA SECA	504	58
MARE	365	91
VILA ISABEL	363	43
BANGU	357	82
CASCADURA	330	56
TIJUCA	327	29
VICENTE DE CARVALHO	322	68
CIDADE DE DEUS	312	37
COMPLEXO DO ALEMÃO	298	45
PENHA	226	198
SANTA CRUZ	143	66

Importante pontuar que, embora a AP 3 e a RP 3.3 sejam os lugares com maior quantidade de tiroteios e baixas, os bairros com mais tiroteios e baixas estão presentes na AP 5/RP 5.1 (Vila Kennedy) e AP 4/RP 4.1 (Praça Seca). Estas informações demonstram a importância de uma análise multiescalar por apresentarem dados que, lidos isoladamente, poderiam ser interpretados como incoerentes ou incorretos.

As análises temporais foram muito importantes para entender que, num olhar histórico, alguns destes bairros tiveram quedas consideráveis de tiroteios ao longo dos anos, enquanto outros ascenderam no mesmo período. Vila Isabel é um bom exemplo: figura entre os cinco bairros com maioria de tiroteios da cidade, mas foi à partir de 2024 que alcançou esse patamar. Podemos atribuir esses valores à sequência de conflitos por disputa de controle do Morro dos Macacos entre

Comando Vermelho (CV) e Terceiro Comando Puro (TCP)¹⁰, que também impactou os territórios vizinhos, vide Tijuca, Maracanã e Andaraí (que também tiveram aumentos nos números de tiroteios no período). A dimensão temporal também ajudou a apontar que, comumente, os tiroteios ocorrem nos **primeiros semestres** dos anos, mais especificamente nos **segundos trimestres**. Numa visão geral, os tiroteios estão **reduzindo** ao longo dos anos.

Considero que, com a coleta, construção de um pipeline e a análise dos dados do Instituto Fogo Cruzado, integrado aos dados do Data.Rio, **foi possível responder a pergunta de partida, assim como as perguntas específicas**, apresentando respostas de forma multiescalar, contemplando a complexidade do tema. Certamente, a problemática dos tiroteios é muito rica em suas possibilidades de análise que, com este projeto, não foram totalmente esgarçadas, mas serviram para o que foi proposto: traçar um panorama geral da relação dos tiroteios no Rio de Janeiro entre 2020 e 2025 com o território, com a letalidade e com a frequência das ocorrências. Outras possibilidades de análise que poderiam ser realizadas são recortes raciais e de gênero, o impacto dos tiroteios nos veículos midiáticos, os diferentes motivos dos tiroteios, dentre outros.

Autoavaliação

O trabalho foi uma tarefa definitivamente desafiadora que se tornou um processo super interessante e divertido (mesmo com um tema tão sensível). Trabalho desde 2024 com dados no grupo de pesquisa/trabalho que participo, de forma totalmente amadora (vide meu histórico de graduação em Arquitetura e Urbanismo e pós-graduação em Planejamento Urbano e Regional), e vinha sentindo a necessidade de buscar aprendizado para entender melhor os processos que eu já fazia e para parar de ser sustentado por tutoriais de youtube e prazos apertados que nos empurram para resultados. Esse foi meu primeiro MVP desta pós-graduação, o que foi, junto das matérias do sprint, muito importantes para me ajudar a aprender o que eu já fazia de uma forma diferente, agora com uma metodologia e programas coerentes para tal.

Ao longo da realização do trabalho (principalmente no estágio mais avançado, nas análises), percebi como poderia otimizar e lapidar mais os dados, além de poder

¹⁰

Disponível

em:

<https://oglobo.globo.com/rio/noticia/2025/12/17/apos-cv-consolidar-dominio-do-morro-dos-macacos-bairros-da-grande-tijuca-tem-queda-nos-roubos-de-veiculo.ghtml>

produzir análises ainda mais aprofundadas¹¹. Mas, para o escopo proposto, fiquei muito satisfeito com o que fiz e com o que concebi de possibilidades do que poderia fazer, que certamente serão base para análises futuras.

No mais, esse MVP foi marcante demais para mim num nível pessoal. Estava muito preocupado no início de sua realização, mas foi um desafio que ajudou a construir minha segurança enquanto um futuro analista de dados!

¹¹ Por exemplo, talvez propor um coeficiente relacionando o total de tiroteios com o total de baixas por bairro para ter um novo indicador.